

RECUPERACIÓN DE LA INFORMACIÓN


TAREA: RAG Conversacional

PERÍODO ACADÉMICO: 2025-A

PROFESOR: Ph.D. Iván Carrera

Nombre: Sergio Vite

Diseño:



Explicación del diseño:

1. Entrada del Usuario (Query)

El sistema recibe como entrada una consulta en lenguaje natural por parte del usuario. Esta query representa una intención que será utilizada para recuperar información relevante y generar una respuesta fundamentada.

2. Módulo de Recuperación de Información (SRI)

Dado un corpus documental preprocesado, el SRI ejecuta una búsqueda semántica utilizando técnicas como embeddings o TF-IDF para encontrar documentos relevantes al query del usuario.

-
- **Entrada:** Query del usuario y Corpus.
 - **Salida:** Fragmentos o documentos relevantes (contexto).
 - **Operación Adicional:** Comparación entre la query y los elementos del corpus, generalmente basada en métricas de similitud (faiss).

3. Generación de Respuesta (LLM)

El contexto recuperado se utiliza como parte del prompt que será alimentado al Modelo de Lenguaje de Gran Escala (LLM).

- **Entrada: Prompt** = contexto recuperado + query del usuario
- **Proceso:** El LLM genera una respuesta coherente basada en la información proporcionada.
- **Salida:** Respuesta generada para el usuario.

4. Gestión del Historial Conversacional

Antes de devolver la respuesta al usuario, el sistema evalúa si la conversación debe mantenerse en memoria (historial) para interacciones multivueeltas.

- **Condición:** Si se requiere contexto conversacional persistente.
 - **Sí:** El sistema agrega el query + respuesta al historial de conversación.
 - **No:** El historial es limpiado (se descarta).
- Esto permite controlar el grado de "memoria" que el modelo conserva entre turnos de diálogo.

5. Interfaz de Usuario

La respuesta generada por el modelo es enviada a través de una interfaz de usuario, como un chat web o aplicación, completando el ciclo del sistema.